

Complementos de Investigação Operacional

6.1 Filas de espera: conceitos, lei de Little e M/M/1

José Firmino Aguiar Madeira

Porquê estudar filas?

Há filas sempre que a procura chega de forma **irregular** a um serviço com capacidade limitada: urgências hospitalares, *call centers*, portagens, caixas de supermercado, carregadores de veículos elétricos, servidores web.


O compromisso

Mais capacidade (servidores, pessoas) custa dinheiro; menos capacidade faz esperar clientes — e esperar também custa (clientes perdidos, máquinas paradas, insatisfação).

Uma surpresa: mesmo com capacidade *acima* da procura média há esperas — e podem ser longas. A culpa é da **variabilidade**: às vezes chegam vários seguidos, às vezes um serviço demora mais.

A teoria das filas (Erlang, 1909, centrais telefónicas de Copenhaga) dá fórmulas para o regime estacionário: em média, quantos esperam e quanto tempo.

Elementos e notação



- λ : taxa média de chegadas (clientes por unidade de tempo);
- μ : taxa média de serviço de *um* servidor;
- s : número de servidores; $\rho = \lambda/(s\mu)$: utilização.

Notação de Kendall: $A/B/s/\text{disciplina}/K/N$

- A, B : chegadas e serviço; **M** = exponencial (Markov);
- s servidores; K = capacidade máxima; N = população;
- disciplina: FIFO, LIFO, SIRO ou GD (geral).

Por omissão $K = \infty, N = \infty$, FIFO: $M/M/1 = M/M/1/GD/\infty/\infty$.

Medidas: L, L_q (n.º médio no sistema / na fila), W, W_q (tempo médio no sistema / na fila), P_n .

Lei de Little (1961)

Em regime estacionário,

$$L = \lambda W, \quad L_q = \lambda W_q, \quad W = W_q + \frac{1}{\mu}.$$

Vale para **qualquer** fila estável (qualquer distribuição, qualquer disciplina): basta conhecer uma das quatro medidas para obter as outras.

Intuição: se chegam 3 carros por hora e cada um fica, em média, 1 hora, então em cada instante estão lá, em média, $3 \times 1 = 3$ carros.

Uso prático: numa loja com 40 clientes lá dentro, em média, e 120 entradas por hora, cada cliente fica em média $40/120 \text{ h} = 20 \text{ min}$ — sem medir ninguém.

O exemplo: um posto de carregamento rápido

Uma estação de serviço tem **um** carregador rápido. Chegam, em média, $\lambda = 3$ carros por hora (chegadas de Poisson); um carregamento demora, em média, 15 min ($\mu = 4$ por hora, exponencial).

M/M/1 ($\rho = \lambda/\mu < 1$)

$$P_0 = 1 - \rho, \quad P_n = (1 - \rho)\rho^n,$$

$$L = \frac{\rho}{1 - \rho}, \quad L_q = \frac{\rho^2}{1 - \rho},$$


$$W = \frac{1}{\mu - \lambda}, \quad W_q = \frac{\lambda}{\mu(\mu - \lambda)}.$$

Medida	Valor	Leitura
ρ	0,75	ocupado 75% do tempo
P_0	0,25	livre 25% do tempo
L	3	carros no posto
L_q	2,25	carros à espera
W	1 h	espera + carga
W_q	45 min	só a esperar

Little confirma: $L = \lambda W = 3 \times 1 = 3$ e
 $L_q = 3 \times 0,75 = 2,25$.

Um carregamento de 15 min custa, em média, 45 min de espera.

Quantos carros estão no posto?




$P_n = (1 - \rho)\rho^n$ decresce geometricamente.

- $P(\text{esperar}) = P(n \geq 1) = \rho = 75\%$;
- $P(n \geq 3) = \rho^3 = 42\%$: em quase metade do tempo há pelo menos 2 carros à espera;
- $P(n \geq 8) = \rho^8 = 10\%$.

A média ($L = 3$) esconde muita variação: há horas calmas e horas com fila longa.

O efeito da utilização: a espera explode perto de 100%



λ (/h)	ρ	W_q
2	0,50	15 min
2,5	0,625	25 min
3	0,75	45 min
3,5	0,875	1 h 45
3,8	0,95	4 h 45

Mais 17% de procura ($3 \rightarrow 3,5$ carros/h) e a espera **mais do que duplica**.

Por isso não se dimensiona um serviço para 95% de ocupação: W_q cresce como $\rho/(1 - \rho)$.

Confirmar com simulação — e ver a cauda

```
import numpy as np
rng = np.random.default_rng(1)
lam, mu, n = 3, 4, 200_000
chegadas = np.cumsum(rng.exponential(1/lam, n))
servico = rng.exponential(1/mu, n)
espera = np.zeros(n); fim = 0.0
for i in range(n):
    inicio = max(chegadas[i], fim)      # espera pelo carro anterior
    espera[i] = inicio - chegadas[i]
    fim = inicio + servico[i]
e = espera[10_000:]                    # descartar o arranque
print(e.mean()*60, (e > 0).mean(), np.quantile(e, .95))
# 45.5 min    0.75    2.72 h
```

	fórmula	simulação
W_q	45 min	45,5 min
$P(\text{esperar})$	0,75	0,75
95% esperam menos de	2,71 h	2,72 h

A espera média é 45 min, mas **1 em cada 20 condutores espera mais de 2 h 40**. No $M/M/1$, $P(W_q > t) = \rho e^{-(\mu-\lambda)t}$.

A simulação dispensa as hipóteses (por exemplo, carregamentos com duração quase fixa) — as fórmulas não.

Exemplo 1 — controlo de bagagens

No aeroporto de Porto Santo há uma só máquina de raios X para verificar bagagens. O aeroporto recebe, em média, 10 passageiros por minuto (tempos entre chegadas exponenciais) e o controlo atende 12 pessoas por minuto (exponencial).

- a) Qual é a probabilidade de a máquina de raios X não estar ociosa?
- b) Qual é a probabilidade de existirem passageiros na fila?
- c) Em média, quantos passageiros estão na fila?
- d) Em média, quanto tempo um passageiro necessita para passar a zona de segurança?

O QUE DEVE FICAR — 6.1

1. $\lambda, \mu, \rho = \lambda/(s\mu)$; em modelos de capacidade infinita, a estabilidade exige $\rho < 1$. Notação de Kendall; medidas L, L_q, W, W_q, P_n .
2. Lei de Little: $L = \lambda W, L_q = \lambda W_q, W = W_q + 1/\mu$ — para qualquer fila estável.
3. M/M/1: $L = \rho/(1 - \rho), W = 1/(\mu - \lambda), P_n = (1 - \rho)\rho^n$.
4. A espera cresce como $\rho/(1 - \rho)$: perto de 100% de utilização, pequenas subidas da procura dão grandes esperas.
5. A média esconde a cauda: simular (ou usar $P(W_q > t)$) para saber quantos esperam muito.

A seguir: 6.2 Capacidade limitada e vários servidores

Referências Lista completa: *Bibliografia da UC*.

- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 11.^a ed., McGraw-Hill, 2021 — Queueing Theory.
- Gross, D., Shortle, J. F., Thompson, J. M., Harris, C. M., *Fundamentals of Queueing Theory*, 4.^a ed., Wiley, 2008.
- Little, J. D. C., A proof for the queuing formula $L = \lambda W$, *Operations Research*, 9(3), 383–387, 1961.

Recursos

- Lista de exercícios 6. `code/python/06_queueing/06_1_mm1/filas.py` (fórmulas e simulação).