

Complementos de Investigação Operacional

6.2 Filas de espera: capacidade limitada e vários servidores

José Firmino Aguilar Madeira

Quando o espaço acaba: M/M/1/K

No posto de 6.1 só há lugar para **4 carros**: 1 a carregar e 3 à espera. Quem chega com os 4 lugares ocupados vai-se embora. Agora $\rho = \lambda/\mu$ pode até ser ≥ 1 : a fila nunca cresce sem limite.

M/M/1/K ($\rho \neq 1$)

$$P_n = \frac{(1 - \rho) \rho^n}{1 - \rho^{K+1}}, \quad n = 0, \dots, K$$

$$\lambda_{\text{ef}} = \lambda(1 - P_K), \quad W = \frac{L}{\lambda_{\text{ef}}}, \quad W_q = \frac{L_q}{\lambda_{\text{ef}}}$$

$L = \sum n P_n$, $L_q = \sum_{n \geq 1} (n - 1) P_n$. Na lei de Little entra a taxa de quem *entra*, λ_{ef} .

K	P_K	λ_{ef} (/h)	L	W (min)
2	0,243	2,27	0,81	21
3	0,154	2,54	1,15	27
4	0,104	2,69	1,44	32
5	0,072	2,78	1,70	37
6	0,051	2,85	1,92	41
∞	0	3	3	60

Com $K = 4$, **10,4% dos condutores desistem** (0,31 por hora); quem fica está, em média, 32 min. A simulação dá 10,2% e 32 min.

Menos espaço $\Rightarrow$ esperas curtas, mas clientes perdidos.

A procura duplica: vários servidores, M/M/s

Com os elétricos a crescer, chegam $\lambda = 6$ carros por hora. Com um carregador ($\mu = 4$), $\rho = 1,5$: a fila cresce sem fim. Quantos carregadores instalar?

M/M/s ($a = \lambda/\mu$, $\rho = a/s < 1$)

$$P_0 = \left[\sum_{n=0}^{s-1} \frac{a^n}{n!} + \frac{a^s}{s! (1 - \rho)} \right]^{-1}$$

$$P(\text{esperar}) = \frac{a^s}{s! (1 - \rho)} P_0, \quad L_q = P(\text{esperar}) \frac{\rho}{1 - \rho}$$

$$W_q = L_q/\lambda, \quad W = W_q + 1/\mu, \quad L = \lambda W.$$

s	$P(\text{esperar})$	L_q	W_q (min)
2	0,643	1,93	19,3
3	0,237	0,24	2,4
4	0,075	0,045	0,45
5	0,020	0,009	0,09

$P(\text{esperar})$ é a **fórmula C de Erlang**, a mesma que se usa para dimensionar *call centers*.

Passar de 2 para 3 carregadores divide a espera por 8.

Fila única ou uma fila por servidor?

Dois carregadores, $\lambda = 6/h$ no total:

- **Duas filas separadas** (cada carro escolhe um carregador e fica nessa fila): duas M/M/1 com $\lambda = 3 \Rightarrow W_q = 45 \text{ min.}$
- **Uma fila única** (o primeiro da fila vai para o carregador que vagar): uma M/M/2 com $\lambda = 6 \Rightarrow W_q = 19,3 \text{ min.}$

O mesmo equipamento, a mesma procura: a fila única corta a espera para menos de metade.

Porquê?

Com filas separadas pode haver um carregador parado e carros à espera no outro. Na fila única isso nunca acontece: a capacidade é partilhada.

É por isso que bancos, CTT e aeroportos usam uma fila única com senha ou serpentina.

Quantos carregadores? Custo contra espera

Cada carregador custa 12 €/h (amortização, manutenção, potência contratada). Cada carro à espera custa 20 €/h (tempo de motoristas de frota, clientes perdidos).

$$\text{custo}(s) = 12s + 20L_q(s) \quad (\text{€ por hora})$$

s	carregadores	espera	total
2	24	38,57	62,57
3	36	4,74	40,74
4	48	0,90	48,90
5	60	0,17	60,17

Decisões

- **Mínimo custo:** 3 carregadores (40,74 €/h); 23,7% dos carros esperam.
- **Nível de serviço** “menos de 10% esperam”: 4 carregadores (7,5%), a 48,90 €/h.

A diferença (8,16 €/h) é o **preço do nível de serviço**. A decisão é da gestão — o modelo diz quanto custa cada opção.

Nos exercícios das aulas o custo de espera aplica-se a L_q (quem está na fila); se se aplicasse a L , somava-se o tempo de serviço.

```
from math import factorial

def mms(lam, mu, s):
    a = lam / mu; rho = a / s
    P0 = 1 / (sum(a**n / factorial(n) for n in range(s))
              + a**s / (factorial(s) * (1 - rho)))
    Pw = a**s / (factorial(s) * (1 - rho)) * P0    # Erlang C
    Lq = Pw * rho / (1 - rho)
    return Pw, Lq, Lq / lam                        # P(esperar), Lq, Wq

lam, mu = 6, 4
for s in range(2, 6):
    Pw, Lq, Wq = mms(lam, mu, s)
    print(s, round(Pw, 3), round(12*s + 20*Lq, 2))
# 2 0.643 62.57 | 3 0.237 40.74 | 4 0.075 48.9 | 5 0.02 60.17
```

Com `simula_mms(6, 4, 3)` (ficheiro do capítulo) a simulação dá $W_q \approx 2,4$ min e 23–24% de carros a esperar.

O mesmo código resolve o exercício do supermercado das aulas (há uma versão em MATLAB e Python no Moodle).

Exemplo 2 — restaurante ($M/M/1/GD/K/\infty$)

Na hora de maior fluxo, um restaurante recebe, em média, 400 clientes por hora e tem uma taxa média de atendimento, dentro dos padrões de qualidade, de 600 clientes por hora. Resolva com o modelo $M/M/1/GD/K/\infty$ com limite $K = 300$; chegadas e atendimento exponenciais.

- a) Qual é o tamanho médio da fila?
- b) Qual é a probabilidade de haver fila?
- c) Qual é o tempo médio de um cliente no sistema?
- d) Compare com o modelo $M/M/1$ (sem limite). O limite $K = 300$ faz diferença? Porquê?

Quantas caixas abrir num supermercado? (TPC)

Um supermercado precisa de decidir quantas caixas devem estar abertas. Em média, chegam 18 clientes por hora e um cliente é atendido, em média, em 4 minutos; chegadas e serviço exponenciais ($M/M/s/GD/\infty/\infty$). O custo do salário à hora é de 20 u.m. e o custo por cliente em espera é de 0,25 u.m. por minuto.

- a) Quantas caixas devem estar abertas para minimizar o custo total?
- b) Quantas caixas garantem que a probabilidade de um cliente ter de esperar é menor do que 5%? Qual é o custo total nessa configuração?

Entrega: por email ao docente, no prazo indicado na aula. Todos os exercícios: **Lista 6**.

O QUE DEVE FICAR — 6.2

1. $M/M/1/K$: $P_n \propto \rho^n$ até K ; quem chega com o sistema cheio perde-se; Little com $\lambda_{\text{ef}} = \lambda(1 - P_K)$.
2. $M/M/s$: P_0 , $P(\text{esperar})$ (Erlang C), $L_q = P(\text{esperar}) \rho / (1 - \rho)$; exige $\lambda < s\mu$.
3. Fila única é melhor do que filas separadas com os mesmos servidores.
4. Dimensionar: minimizar custo de servidores + custo de espera, ou cumprir um nível de serviço — e saber quanto custa a diferença.

A seguir: 6.3 Quando os clientes são poucos: população finita ($M/M/R$)

Referências Lista completa: *Bibliografia da UC*.

- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 11.ª ed., McGraw-Hill, 2021 — Queueing Theory (M/M/s, capacidade finita, modelos de decisão).
- Gross, D., Shortle, J. F., Thompson, J. M., Harris, C. M., *Fundamentals of Queueing Theory*, 4.ª ed., Wiley, 2008.
- Taha, H. A., *Operations Research: An Introduction*, 10.ª ed., Pearson, 2017 — modelos de custo.

Recursos

- Lista de exercícios 6. `code/python/06_queueing/06_2_mmk_mms/filas_mms.py`.