

Complementos de Investigação Operacional

8.1 Decisão multicritério: o AHP, comparações par a par e consistência

José Firmino Aguilar Madeira


Quando não há uma só unidade de medida

Nos capítulos 2 a 7 havia sempre **uma** medida: tempo, custo, n.º de clientes em espera. Muitas decisões reais não são assim.

Uma empresa de distribuição urbana vai comprar carrinhas elétricas e hesita entre três modelos, A, B e C. Interessam:

- o **custo** de aquisição (€);
- a **autonomia** (km);
- a **carga** útil (kg);
- a **assistência** pós-venda (sem unidade: opinião).

Ninguém sabe quantos euros vale um quilómetro de autonomia.



AHP (*Analytic Hierarchy Process*, Saaty, anos 70): decompor a decisão numa hierarquia, comparar **dois a dois** em cada nível e juntar tudo num número por alternativa.

A escala de Saaty

a_{ij}	i face a j
1	igual importância
3	moderadamente mais importante
5	fortemente mais importante
7	muito fortemente mais importante
9	extremamente mais importante
2, 4, 6, 8	valores intermédios

Reciprocidade: $a_{ji} = 1/a_{ij}$ e $a_{ii} = 1$. Com n critérios só se pedem $n(n-1)/2$ juízos (aqui 6).

Como aparece nos testes: uma régua por par de critérios.



A marca do lado esquerdo favorece o critério da esquerda. Aqui a marca está no 3 da direita: autonomia moderadamente mais importante do que custo, ou seja, $a_{\text{custo},\text{aut}} = 1/3$.

Escala de razão: “5” quer dizer “cinco vezes mais importante”.

Os pesos dos critérios

A gestão da empresa comparou os quatro critérios:

	cust.	aut.	carga	assist.
custo	1	2	3	5
autonomia	1/2	1	2	3
carga	1/3	1/2	1	2
assistência	1/5	1/3	1/2	1
soma	2,033	3,833	6,5	11

Passo 1: dividir cada coluna pela sua soma.

Passo 2: o peso de cada critério é a média da sua linha.

	matriz normalizada				peso w
custo	0,492	0,522	0,462	0,455	0,482
autonomia	0,246	0,261	0,308	0,273	0,272
carga	0,164	0,130	0,154	0,182	0,158
assistência	0,098	0,087	0,077	0,091	0,088

O custo pesa quase metade da decisão; a assistência menos de 9%.

Se os juízos fossem perfeitamente coerentes ($a_{ij} = w_i/w_j$), as quatro colunas normalizadas seriam iguais: a média só “limpa” pequenas diferenças.

Os juízos são coerentes?

Se custo = 2× autonomia e autonomia = 2× carga, a coerência pede custo $\approx 4 \times$ carga. A gestão disse 3: quase.

Índice e razão de consistência

$$\lambda_{\max} \approx \frac{1}{n} \sum_i \frac{(Aw)_i}{w_i}, \quad IC = \frac{\lambda_{\max} - n}{n - 1}, \quad RC = \frac{IC}{IA_n}$$

Aceita-se a matriz se $RC < 0,10$.

$\lambda_{\max} \geq n$, com igualdade só se a matriz for perfeitamente coerente.

Carrinhas:

$$Aw = (1,940; 1,093; 0,631; 0,354)$$

$$(Aw)_i/w_i = 4,021; 4,021; 4,005; 4,011$$

$$\lambda_{\max} = 4,015; \quad IC = 0,0048;$$

$$RC = 0,0048/0,90 = \mathbf{0,005}: \text{ coerente.}$$

Índice aleatório de Saaty

n	3	4	5	6	7	8	9
IA_n	0,58	0,90	1,12	1,24	1,32	1,41	1,45

IA_n : IC médio de matrizes preenchidas ao acaso.

Para $n \leq 2$ não há incoerência possível.

Quando os juízos não batem certo

Suponha que, na mesma reunião, alguém insiste que a carga é **duas vezes mais importante** do que o custo ($a_{13} = 1/2$), mantendo os outros cinco juízos.

Resultado: $\lambda_{\max} = 4,467$ e **$RC = 0,173 > 0,10$** . Os pesos passam a 0,343; 0,292; 0,276; 0,089 — mas não merecem confiança.

Onde está o problema? Compare cada juízo a_{ij} com o que os pesos implicam, w_i/w_j : o rácio $a_{ij} w_j/w_i$ devia ser perto de 1.

$a_{ij} w_j/w_i$ com $a_{13} = 1/2$

	cust.	aut.	carga	assist.
custo	1	1,70	0,40	1,30
autonomia	0,59	1	1,89	0,92
carga	2,49	0,53	1	0,65
assistência	0,77	1,09	1,54	1

O par custo–carga é o mais afastado: é esse juízo que se devolve ao decisor. Com $a_{13} = 3$ volta-se a $RC = 0,005$; com $a_{13} = 1$ ainda se aceita ($RC = 0,069$).

O AHP não corrige o decisor: mostra-lhe onde se contradiz.

Normalização das colunas (nas aulas)

Média das linhas da matriz normalizada. Contas à mão; é o método dos testes e da folha de Excel do Moodle.

Vetor próprio (Saaty)

w é o vetor próprio de A associado ao maior valor próprio, $Aw = \lambda_{\max} w$, normalizado para somar 1. É a definição original; em Python, `numpy.linalg.eig`.

	colunas	vetor próprio
custo	0,4824	0,4829
autonomia	0,2718	0,2720
carga	0,1575	0,1570
assistência	0,0883	0,0882
$\lambda_{\max}$	4,0145	4,0145

Com juízos coerentes, os dois métodos coincidem; com $RC < 0,10$ as diferenças ficam na terceira casa decimal. Quando divergem muito, o problema é a matriz, não o método.

Um critério qualitativo: a assistência

Para a assistência não há números: a empresa falou com outros clientes e comparou as marcas dois a dois.

assist.	A	B	C	prioridade
A	1	1/3	3	0,261
B	3	1	5	0,633
C	1/3	1/5	1	0,106

$\lambda_{\max} = 3,039$; $IC = 0,019$; $RC = 0,033$: coerente.

O mesmo procedimento serve para **todos** os níveis:

1. comparar os critérios $\Rightarrow$ pesos w ;
2. em cada critério, comparar as alternativas $\Rightarrow$ prioridades locais;
3. pontuação final = soma ponderada das prioridades locais.

Para custo, autonomia e carga há valores medidos: não é preciso perguntar opiniões. Como os usar é o tema de **8.2**.

```
import numpy as np
IA = {3: 0.58, 4: 0.90, 5: 1.12, 6: 1.24, 7: 1.32}

def prioridades(A, metodo='colunas'):
    A = np.asarray(A, float); n = len(A)
    if metodo == 'colunas':
        w = (A / A.sum(0)).mean(1)
        lam = np.mean(A @ w / w)
    else:
        # vetor próprio
        val, vec = np.linalg.eig(A); k = val.real.argmax()
        w = abs(vec[:, k].real); w /= w.sum(); lam = val[k].real
    IC = (lam - n) / (n - 1)
    return w, lam, IC / IA[n]          # pesos, lambda_max, RC

A = [[1, 2, 3, 5], [1/2, 1, 2, 3], [1/3, 1/2, 1, 2], [1/5, 1/3, 1/2, 1]]
print(prioridades(A))
# pesos 0.482 0.272 0.158 0.088; lambda_max 4.015; RC 0.005
```

Ficheiro completo: code/python/
08_ahp/08_1_ahp/ahp.py.

Experimente: troque a_{13} por $1/2$ e veja o RC subir para 0,173. Que outro juízo teria de mudar para voltar a ser coerente?

Exemplo 1 — comparar três frutos

Um consumidor comparou três frutos, F1, F2 e F3, dois a dois: F2 é moderadamente preferível a F1 (3), F1 é fortemente preferível a F3 (5) e F2 é muito fortemente preferível a F3 (7). Determine as prioridades e verifique a consistência dos juízos.

Exemplo 2 — escolher entre duas propostas de emprego

Um recém-licenciado tem duas propostas, A e B, e três critérios. Matriz de comparação dos critérios:

$\begin{pmatrix} 1 & 1/7 & 1/2 \\ 7 & 1 & 5 \\ 2 & 1/5 & 1 \end{pmatrix}$. No critério 1 (salário) A oferece 2000 € e B 2500 €; no critério 2, A é

moderadamente preferível a B (3); no critério 3, A é fortemente preferível a B (5). Que proposta deve aceitar? Os juízos são coerentes?

Lista 8 — Exercício 1 (TPC)

AHP com 3 critérios e 3 alternativas (resolução em Python no Moodle)

Pretende-se escolher a melhor de três alternativas, A, B e C, com três critérios, C1, C2 e C3. Matriz dos

critérios: $\begin{pmatrix} 1 & 1/2 & 4 \\ 2 & 1 & 7 \\ 1/4 & 1/7 & 1 \end{pmatrix}$. Matrizes das alternativas em C1, C2 e C3:

$$\begin{pmatrix} 1 & 1/3 & 3 \\ 3 & 1 & 5 \\ 1/3 & 1/5 & 1 \end{pmatrix}, \quad \begin{pmatrix} 1 & 5 & 1/7 \\ 1/5 & 1 & 1/8 \\ 7 & 8 & 1 \end{pmatrix}, \quad \begin{pmatrix} 1 & 2 & 1/3 \\ 1/2 & 1 & 1/4 \\ 3 & 4 & 1 \end{pmatrix}.$$

Calcule os pesos, as razões de consistência de todas as matrizes e a pontuação final. Que alternativa escolhe? Comente a consistência.

Entrega: por email ao docente, no prazo indicado na aula. Todos os exercícios: [Lista 8](#).

O QUE DEVE FICAR — 8.1

1. O AHP serve quando os critérios não têm uma unidade comum: hierarquia objetivo $\rightarrow$ critérios $\rightarrow$ alternativas.
2. Escala de Saaty de 1 a 9, matriz recíproca, $n(n-1)/2$ juízos.
3. Pesos: normalizar as colunas e fazer a média das linhas (ou vetor próprio de $\lambda_{\max}$).
4. Consistência: $IC = (\lambda_{\max} - n)/(n - 1)$, $RC = IC/IA_n < 0,10$. Se falhar, procurar o juízo com $a_{ij}w_j/w_i$ mais longe de 1 e devolvê-lo ao decisor.

A seguir: 8.2 Atributos quantitativos e agregação.

Referências Lista completa: *Bibliografia da UC*.

- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 11.ª ed., McGraw-Hill, 2021 — Decision Analysis.
- Saaty, T. L., How to make a decision: the analytic hierarchy process, *European Journal of Operational Research*, 48(1), 9–26, 1990.
- Saaty, T. L., Decision making with the analytic hierarchy process, *International Journal of Services Sciences*, 1(1), 83–98, 2008.
- Taha, H. A., *Operations Research: An Introduction*, 10.ª ed., Pearson, 2017 — AHP.

Recursos

- Lista de exercícios 8. `code/python/08_ahp/08_1_ahp/ahp.py`. Moodle: resoluções em Python e MATLAB.